EVAL MÜFREDATI · 8 MODÜL

Ürünün çalıştığını nasıl bilirsin?

LLM ürünleri için eval: hata analizinden istatistiğe, birincil kaynaklarla ve her modülde bir alıştırmayla.

Eğitim · Ekim 2026

ÇALIŞMA YÖNTEMİ

Her modül dört parçadan oluşur

Fikir

Tek cümleyle söylenebilen bir ilke.

Örnek

İlkenin gerçek bir üründe nasıl göründüğü.

Alıştırma

Örnek botun ya da kendi ürününün çıktılarıyla yapılan iş.

Kaynak

Blog özeti yerine birincil kaynak: makale ya da araç dokümanı.

Kural: her modül bir alıştırmayla biter. Eval, çıktı okuyup etiketleyerek öğrenilir.

MÜFREDAT HARİTASI

Her modül bir soruyu cevaplar ve bir dosya bırakır

Modül	Cevapladığı soru	Elinde kalan
1 · Neden	Şu an değişiklikleri neye bakarak onaylıyorum?	Onay alışkanlığı notu
2 · Hata analizi	Ürün gerçekte nerede, ne sıklıkta hata yapıyor?	taksonomi.md
3 · Katmanlar	Hangi hata kodla, hangisi judge ile yakalanır?	Katman eşlemesi
4 · Judge	Judge’a ne kadar güvenebilirim?	judges/*.md, uyum tablosu
5 · İstatistik	Bu fark gerçek mi, gürültü mü?	Aralıklı skor raporu
6 · Veri seti	Set gerçek kullanımı temsil ediyor mu?	golden.jsonl
7 · Süreç	Eval ne zaman, hangi araçla koşar?	Çalışan eval komutu
8 · Ödev	Hepsi kendi ürünümde çalışıyor mu?	Teslim paketi

EĞİTİM BOYUNCA ÖRNEK PROJE

Bir e-ticaret destek botu

Ne yapıyor

İade, kargo, değişim ve sipariş sorularını cevaplıyor. Gerekirse konuşmayı bir temsilciye devrediyor.

Elindekiler

Mağazanın politika metni, sipariş sorgulama aracı, temsilciye devir aracı.

Politika

14 gün iade hakkı. Kargo 2–4 iş günü. Değişimde kargo ücreti müşteriye ait.

Neden bu proje: hataları herkes tanır, ve eval'in bütün katmanları burada doğal olarak ortaya çıkar. Bir link kodla kontrol edilir, politikaya uyum judge ister, çözülme oranı ise ancak canlıda ölçülür.

Kurgu proje: mağaza, politika ve bütün konuşmalar eğitim için uyduruldu

BÜYÜK RESİM

Bot iyi çalışıyor mu? Altı adımda cevap

1 · Modül 2
Konuşmaları oku, gördüğün hataları not et.

2 · Modül 2
Hataları grupla, hangisi kaç kez oluyor say.

3 · Modül 3
Basit hataları birkaç satır kodla otomatik yakala.

4 · Modül 4
Zor hataları ikinci bir yapay zekâya, yani hakeme notlat.

5 · Modül 4
Hakemin doğru not verdiğini insan notlarıyla kontrol et.

6 · Modül 5
Çıkan sayının ne kadar kesin olduğunu hesapla.

Modül 6 ve 7 bu işi tekrarlanabilir yapar: doğru test seti ve doğru araçlar. Modül 8’de katılımcı altı adımı kendi ürününde baştan sona uygular.

TERİMLER 1/2 · TEMEL KAVRAMLAR

Eğitimde geçen kelimeler

Terim	Düz Türkçesi	Destek botunda
Eval	Sistemi bir sınavdan geçirip sonucu sayıyla ölçmek	40 konuşmada %72 doğru
Test seti	Doğru davranışı önceden bilinen örnekler	“İade süresi?” → “14 gün” geçmeli
Hata taksonomisi	Gerçek hataların gruplanmış listesi	Uydurma link, yanlış politika
Kod assertion	Kodla yazılmış otomatik kontrol	Verdiği link sitede var mı?
Judge (hakem)	Cevaba not veren ikinci bir yapay zekâ	“Politikayla çelişiyor mu?”
Geçti / kaldı	Hakemin evet/hayır kararı, puan değil	30 gün dedi → KALDI
Few-shot örnek	Hakeme gösterilen çözülmüş örnekler	Uzmanın notladığı 3 konuşma

TERİMLER 2/2 · ÖLÇÜM

Sayılarla ilgili kelimeler

Terim	Düz Türkçesi	Destek botunda
Uyum	Hakemle insanın aynı kararı verme oranı	20’nin 16’sı → %80
TPR	İyi cevapları “iyi” bulma oranı	14 iyinin 12’si
TNR	Kötü cevapları yakalama oranı	6 kötünün 4’ü
Kappa	Şans payı çıkarılmış uyum	0,52 = orta
Hata payı	Skorun tekrar ölçülse ne kadar oynayacağı	%80 ± 11 puan
Eşleştirilmiş karşılaştırma	İki versiyonu aynı sorularla kıyaslamak	Eski ve yeni prompt, aynı 40 soru
Güç analizi	Kaç örnek gerektiğini önceden hesaplamak	10 puanlık fark için ≈ 250 örnek

MODÜL 1 · NEDEN

Eval yoksa her prompt değişikliği bir tahmindir



Goodhart yasası: bir ölçüt hedefe dönüşünce iyi bir ölçüt olmaktan çıkar. Eval setini bu yüzden hata analiziyle tazelersin.

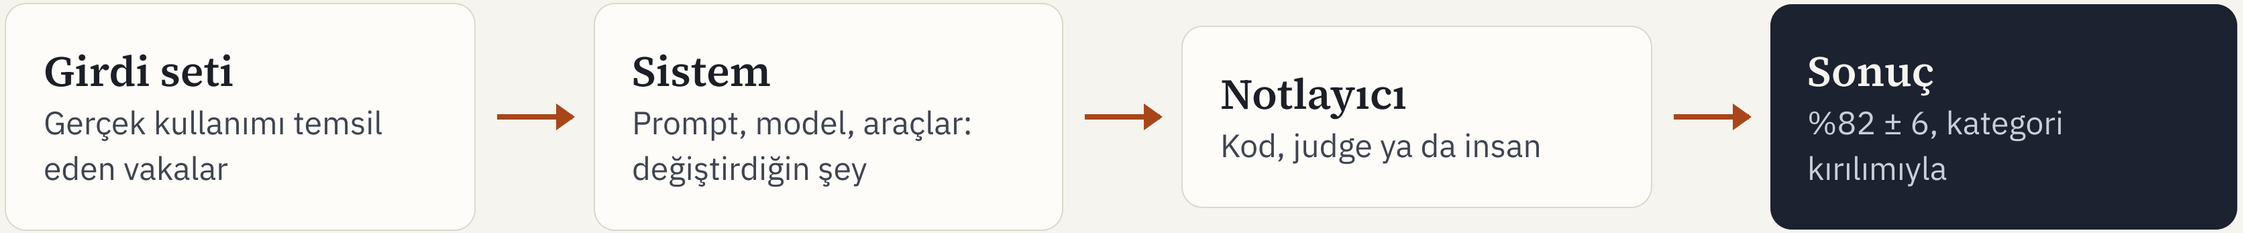
ALIŞTIRMA

Son beş prompt değişikliğini neye bakarak onayladığını yaz: kaç örneğe baktın, kim karar verdi, neyi hiç kontrol etmedin?

MODÜL 1 · TANIM

Eval bir oran ölçer, bir hata payıyla

Ne demek? Eval, botu bir sınavdan geçirip “yüzde kaç doğru?” sorusuna sayıyla cevap vermek.



	Birim testi	Eval
Çıktı	Deterministik	Her koşumda değişebilir
Hedef	%100 geçmek	Oranı izlemek ve yükseltmek
Kırmızı	Bir şey bozuldu	Oran, hata payından fazla düştü

MODÜL 2 · HATA ANALİZİ

Önce oku, sonra ölç

Ne demek? Kategorileri masa başında uydurma. Önce konuşmaları oku, notları sonra grupla.

1

Topla

50–100 gerçek çıktı. Rastgele al, zor vakaları sonra eklersin.

2

Açık kodla

Her çıktıya serbest bir not: neyi yanlış yaptı? Kategori yok.

3

Eksen kodla

Notları ortak başlıklara topla. Hata taksonominin ilk hâli bu.

4

Say

Her kategori kaç kez geçiyor? En sık üçü ilk eval'lerin olur.

Açık ve eksen kodlama nitel araştırmadan gelir. Çıktı okunmadan yazılan eval, modelin hiç yapmadığı bir hatayı ölçebilir ve asıl hatayı kaçırır.

Kaynak: Strauss & Corbin, Basics of Qualitative Research

MODÜL 2 · ÇALIŞILMIŞ ÖRNEK: AÇIK KODLAMA

Destek botunun altı konuşmasına not

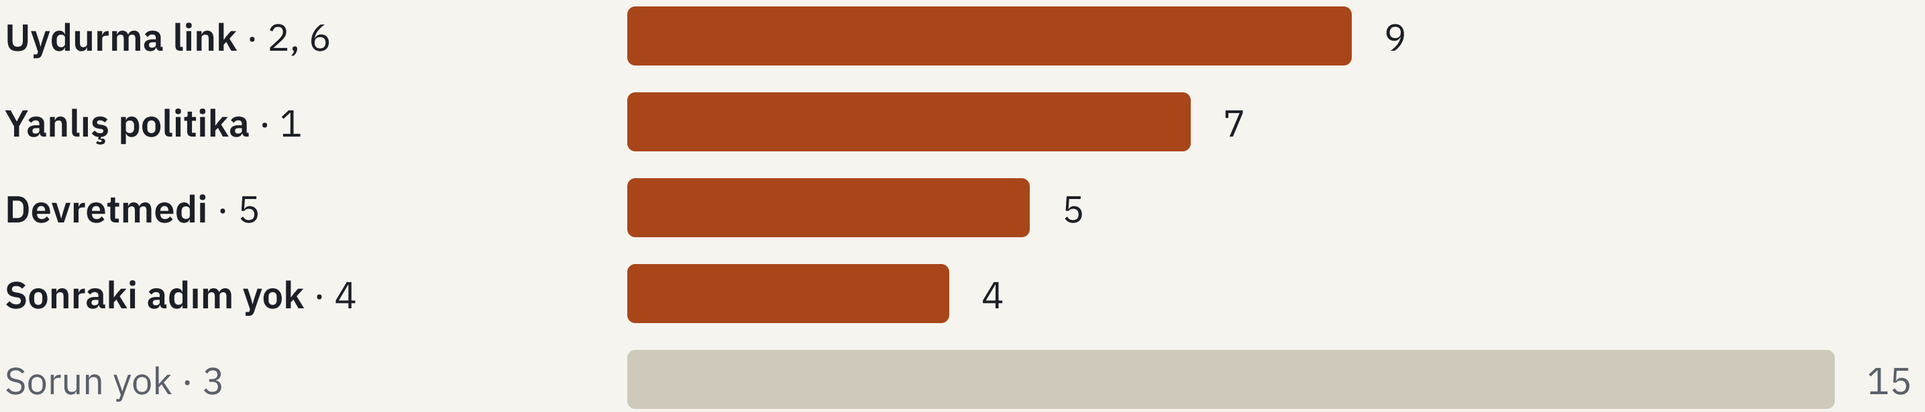
#	Müşterinin sorusu	Açık kod notu (serbest, kategori yok)
1	İade süresi ne kadar?	Politika 14 gün diyor, bot 30 gün dedi.
2	Kargom nerede?	Takip için sitede olmayan bir link verdi.
3	Beden değişimi yapabilir miyim?	Sorun yok.
4	Ürünüm hasarlı geldi.	Özür diledi, genel bir metin yazdı. Ne yapılacağını söylemedi.
5	Bir temsilciyle görüşmek istiyorum.	Müşteri iki kez istedi, bot devretmedi.
6	İade formunu nereden doldururum?	“/iade-formu” diye bir sayfa uydurdu.

Notlar düz cümle. Henüz “link sorunu” gibi bir başlık yok. Başlıklar bir sonraki geçişte gelir.

Örnek veri: konuşmalar ve notlar eğitim için kurgulandı

MODÜL 2 · ÇALIŞILMIŞ ÖRNEK: EKSEN KODLAMA

40 konuşma, dört kategori



40 konuşmanın 25’inde hata var. İlk üç kategori hataların %84’ü (21/25). İlk eval’ler bunlar olur, “sonraki adım yok” bekleyebilir.

Örnek veri: sayılar eğitim için kurgulandı · kategori adının yanındaki rakamlar önceki slayttaki notlar

MODÜL 2 · SAHADA KURALLAR

Hata analizini işletmenin dört kuralı

Tek etiketleyici

Bir alan uzmanı, yani sen. Birden çok kişi tutarsız etiket üretir ve judge neye hizalanacağını bilemez.

İlk hata yeter

Her çıktıda en önemli hatayı yaz. Hepsini yazmaya çalışırsan 40 çıktı bir hafta sürer.

Doygunlukta dur

Son 10 çıktıda yeni kategori çıkmadıysa taksonomi yeterli. Daha fazla okumak sayıyı değiştirir, listeyi değil.

Değişince tekrar oku

Model ya da prompt değişince yeni hata türleri çıkar. Taksonomi bir kez yazılıp bırakılmaz.

Kaynak: Husain, Creating a LLM-as-a-Judge That Drives Business Results (2024) · “son 10 çıktı” eşiği bu müfredatın önerisi

MODÜL 2 · KRİTER KAYMASI

Kriterler çıktıyı okurken ortaya çıkar

Shankar ve arkadaşları (2024), değerlendirme kriterlerinin çıktılar notlanırken tanımlandığını ve notlandıkça değiştiğini gösterdi. Bunun adı kriter kayması.

Sonuç: kriteri masa başında yazıp ölçmeye geçme. Önce oku, kriteri çıktılardan çıkar, yazdığın kriteri yeni çıktılarla tekrar sına.

ALIŞTIRMA

Okumaya başlamadan önce örnek botta ya da kendi ürününde en sık göreceğini düşündüğün üç hatayı yaz. Sonra 30 konuşmayı aç, açık ve eksen kodla, gerçek ilk üçü çıkar. İki listeyi karşılaştır.

Kaynak: Shankar vd., Who Validates the Validators? (2024)

MODÜL 3 · EVAL KATMANLARI

Hangi hatayı hangi yöntem yakalar?

Katman	Neyi yakalar	Maliyet	Ne zaman koşar
Kod assertion	Format, JSON şeması, yasak ifade, uzunluk	Çok düşük	Her değişiklikte
LLM judge	Tanımlanabilen öznel kriter: eksiksizlik, ton, kurala uyum	Orta	Her değişiklikte, örneklemle
İnsan değerlendirmesi	Judge'ın kaçırdığı hatalar ve judge'ın kendi doğruluğu	Yüksek	Judge kurulurken ve düzenli aralıkla
A/B ve ürün metriği	Gerçek kullanıcıdaki etki	En yüksek	Yayından sonra

Kaynak: Husain, Your AI Product Needs Evals (2024). Katmanlar onun üç seviyesinden uyarlandı

MODÜL 3 · ÇALIŞILMIŞ ÖRNEK: KOD ASSERTİON

En sık hata judge istemiyor

Ne demek? Bazı hataları basit bir kod satırı yakalar, yapay zekâ hakeme gerek kalmaz.

Kontrol	Kod	Yakaladığı
Cevap çok uzun değil	`len(reply) ⩽ 1200`	Format
Sipariş no doğru biçimde	`re.fullmatch(r"\d{8}", order_id)`	Format
Her link sitede var	`all(u in ALLOWED_URLS for u in links)`	**Uydurma link**
Temsilci istenince devir	`not asked_agent or "handoff" in tools`	**Devretmedi**

Taksonomideki birinci ve üçüncü kategori, 25 hatanın 14’ü, kodla yakalanıyor. Ücretsiz, deterministik, her commit’te koşar.

Alan adları (links, tools, asked_agent) örnek; botun gerçek log biçimine göre uyarlanır

MODÜL 3 · KATMAN SEÇİMİ

Her kategori için iki soru

1. Kodla kontrol edilebilir mi? Evet → assertion

→

2. Geçti/kaldı tanımı yazılabilir mi? Evet → judge

→

İkisi de hayır → kriter henüz net değil, önce onu netleştir

Kategori	Katman	Neden
Uydurma link	Kod	Link izin listesinde mi?
Devretmedi	Kod + judge	Açık istek kodla, dolaylı istek judge ile
Yanlış politika	Judge	“Politikayla çelişiyor mu” yargı ister
Sonraki adım yok	Judge	“Müşteri ne yapacağını biliyor mu” tanımlanabilir

MODÜL 3 · ALIŞTIRMA

Her kategoriyi bir katmana yerleştir

1. Taksonomindeki her kategori için iki soruyu cevapla: kodla mı, judge ile mi?
2. Kod tarafına düşen her kontrolü yaz.
3. Her kontrole bilerek bozulmuş bir çıktı ver ve düştüğünü gör. Doğru bir çıktıyla geçtiğini de gör.

> **BİTTİ SAYILIR**
>
> Her kontrol en az bir kez kırmızı, bir kez yeşil yandı.

MODÜL 4 · LLM-AS-JUDGE

Hakem puan mı versin, evet/hayır mı?

KAÇIN · 1–5 PUAN

3 ile 4 arasındaki farkı kimse tanımlayamaz. Puanlar kayar, judge ile insanın uyumu ölçülemez.

TERCİH ET · GEÇTİ / KALDI

Her kriter için tek soru: bu çıktı X'i yapıyor mu? Kararın tanımı yazılabilir, uyumu ölçülebilir.

Judge prompt'unun anatomisi

1. Tek kriter, tek judge
2. Geçti ve kaldı tanımı, sınır vakasıyla birlikte
3. Etiketlenmiş birkaç örnek (few-shot)
4. Önce gerekçe, sonra karar

Kaynak: Husain, Creating a LLM-as-a-Judge That Drives Business Results (2024)

MODÜL 4 · ÇALIŞILMIŞ ÖRNEK: JUDGE PROMPT'U

"Yanlış politika" judge'ı

```
Tek bir şeye bakıyorsun: botun cevabı
politika metniyle çelişiyor mu?

GEÇTİ: Cevaptaki her süre, ücret ve koşul
politika metninde aynen var.
KALDI: En az bir süre, ücret ya da koşul
politikayla çelişiyor ya da politikada yok.

Sınır vakası: bot "emin değilim, temsilciye
aktarıyorum" diyorsa çelişki değil.

<örnekler>{{etiketli_ornekler}}</örnekler>
<politika>{{politika}}</politika>
<konuşma>{{konusma}}</konuşma>

Önce gerekçe, son satırda GEÇTİ ya da KALDI.
```

Tek kriter. Ton ya da format sorulmuyor.

İkili tanım. İki durum birbirini dışlıyor, arada bir şey yok.

Sınır vakası. Taksonomi dosyasından geliyor.

Örnekler. Uzmanın etiketleri ve eleştirileri, yalnız geliştirme setinden.

Önce gerekçe. Karar sona kalıyor.

MODÜL 4 · CRİTİQUE SHADOWİNG

Etiketin yanına bir eleştiri yaz

#	Karar	Eleştiri (yeni bir çalışanın anlayacağı kadar açık)
1	KALDI	Politika iade süresini 14 gün diyor, bot 30 gün dedi. Müşteri 20. günde iade etmeye çalışıp reddedilir.
3	GEÇTİ	Değişim koşulları politikadakiyle aynı. Kargo ücretinin müşteriye ait olduğunu doğru söyledi.
7	GEÇTİ	Kampanyalı ürünün iadesini bilmediğini söyleyip temsilciye aktardı. Kurala göre çelişki sayılmaz.

1 · Uzmanı seç | 2 · Veri seti | 3 · Karar + eleştiri | 4 · Hataları düzelt | 5 · Judge'ı kur | 6 · Uyumu ölç

Kaynak: Husain, Creating a LLM-as-a-Judge That Drives Business Results (2024) · eleştiriler örnek veri

MODÜL 4 · JUDGE YANLILIKLARI

Judge da yanılır, hep aynı yönlere

Ne demek? Hakem olarak kullanılan yapay zekânın da bilinen, tekrarlayan kör noktaları var.

Konum

İkili karşılaştırmada belirli bir sıradaki cevabı kayırır.

Önlem: sırayı değiştirip iki kez sor. Kararlar uyuşmazsa berabere say.

Uzunluk

Daha uzun cevabı, daha iyi olmasa da tercih eder.

Önlem: kriterde uzunluğun ödül olmadığını yaz, uzunluğu ayrı ölç.

Kendini kayırma

Kendi model ailesinin ürettiği cevaba yüksek not verebilir.

Önlem: judge'ı insan etiketiyle hizala. Gerekirse başka bir modelle çapraz kontrol et.

Kaynak: Zheng vd., Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena (2023)

MODÜL 4 · JUDGE'I DOĞRULAMAK

Hakeme nasıl güveneceğiz?

	İnsan: geçti	İnsan: kaldı
Judge: geçti	Doğru pozitif	Yanlış pozitif
Judge: kaldı	Yanlış negatif	Doğru negatif

TPR: insanın "geçti" dediklerinin ne kadarına judge da geçti dedi.

TNR: insanın "kaldı" dediklerinin ne kadarına judge da kaldı dedi.

Ham uyum yanıltır: çıktıların %90'ı iyiyse her şeye "geçti" diyen judge %90 uyum alır ve tek hata yakalamaz. Cohen's kappa şans payını düşer.

Etiketli veriyi ikiye böl: judge prompt'unu geliştirme setinde düzelt, test setinde bir kez ölç. Test setine bakarak düzeltirsen ölçtüğün şey ezber olur.

Kaynak: Shankar vd. 2024; Husain'in judge hizalama yazıları

MODÜL 4 · ÇALIŞILMIŞ ÖRNEK: HAKEMİ KONTROL ETMEK

%80 uyum, ama hataların üçte biri kaçıyor

20 konuşma · insan: 14 iyi, 6 kötü

	İnsan: iyi	İnsan: kötü
Hakem: iyi	12	2
Hakem: kötü	2	4

20 konuşmanın 16’sında aynı karar → **%80 uyum**

14 iyinin 12’sini “iyi” buldu → **%86** (TPR)

6 kötünün yalnızca 4’ünü yakaladı → %67 (TNR)

Her şeye “iyi” diyen tembel hakem bile %70 alırdı

Şans payı çıkarılınca (kappa) → **0,52, orta**

Ders: tek bir uyum sayısına bakma, kötüleri ne kadar yakaladığına ayrıca bak. Ve 6 kötü örnek az: en az 15–20 kötü örnek koymadan bu sayıya güvenme.

Örnek veri · 15–20 kötü örnek bu eğitimin önerisi

MODÜL 4 · JUDGE'I DÜZELTMEK

Yanlış kararları oku, sebebi düzelt

1

Geliştirme setindeki her yanlış kararı ve gerekçesini oku.

2

Ortak bir sebep bul: tanım mı belirsiz, sınır vakası mı eksik?

3

Tanımı ya da sınır vakasını düzelt, bir örnek ekle.

4

Geliştirme setinde tekrar ölç. Bittiğinde test setinde bir kez.

TUZAK

Her yanlış kararı few-shot örneği olarak eklemek. Judge geliştirme setini ezberler, uyum yükselir, test setinde düşer. Örnek, bir sebebi temsil ettiği için eklenir.

MODÜL 4 · ALIŞTIRMA

İlk judge’ını kur ve ölç

1. Judge gerektiren bir kategori seç. 40 çıktıya karar ve eleştiri yaz.
2. 20 geliştirme, 20 test olarak böl. Test setinde en az 6 “kaldı” olsun.
3. Judge prompt’unu yaz, geliştirme setinde düzelt.
4. Test setinde bir kez koş. TPR, TNR ve kappa’yı hesapla.

BİTTİ SAYILIR

Uyum tablosu dolu ve test setine düzeltme sırasında hiç bakılmadı.

MODÜL 5 · İSTATİSTİK

50 örnekte %80, aslında %69 ile %91 arası

Ne demek? Az soruyla ölçülen skor kesin değildir. Gerçek değer bir aralıkta bir yerdedir.

±11

puan hata payı, n = 50, skor %80

±4

puan hata payı, n = 400, skor %80

Standart hata = √(p(1−p)/n); %95 güven aralığı ≈ ±1,96 × SE. Örnek sayısını dört katına çıkarmak hata payını yarıya indirir.

Kaynak: Miller, Adding Error Bars to Evals (2024)

MODÜL 5 · ADIM ADIM HATA PAYI

50 örnekte %80’in aralığı

Ne demek? Skorun yanına “artı eksi kaç puan” yazmanın hesabı, beş adımda.



Okuma: aynı sistemi başka 50 örnekle ölçseydin skor büyük olasılıkla %69 ile %91 arasında bir yere düşerdi.

Python: se = (p * (1 - p) / n) ** 0.5, sonra p ± 1.96 * se.

Sınır: bu formül n büyükken çalışır. Birkaç yüzün altında bir sonraki slayttaki yöntemleri kullan.

Kaynak: Miller, Adding Error Bars to Evals (2024)

MODÜL 5 · KÜÇÜK ÖRNEKLEM

Az örnekte basit formül %100'ü aşar

Ne demek? Örnek azken basit formül saçma sonuç verir. Küçük setlerde başka hesap kullanılır.

KAÇIN · CLT

[%77, %103]

Üst sınır imkânsız bir değer. Aralık da olması gerekenden dar.

TERCİH ET · WİLSON

[%70, %97]

0 ile 1 arasında kalır, uçlara yakın oranlarda doğru davranır.

TERCİH ET · BAYES

[%70, %97]

Beta(1 + S, 1 + N − S) = Beta(19, 3) dağılımının %2,5 ve %97,5 noktaları.

Bitirme ödevindeki test seti 20 örnek. Orada CLT değil, Wilson ya da Bayes kullan.

Kaynak: Bowyer, Aitchison, Ivanova, Don't Use the CLT in LLM Evals With Fewer Than a Few Hundred Datapoints (ICML 2025)

MODÜL 5 · KARŞILAŞTIRMA

İki promptu karşılaştırmanın beş kuralı

Kural	Neden
Standart hatayı raporla	Hata payı olmayan tek bir skor yorumlanamaz.
Kümelenmiş SE	Aynı belgeden çıkan sorular bağımsız değildir. Onları bağımsız saymak hata payını küçük gösterir.
Eşleştirilmiş fark	A ile B'yi aynı örneklerde koş, örnek başına farkı analiz et. Varyans düşer.
Tekrarla	Model rastgele çalışır. Her örneği birkaç kez koşup ortalamak ölçüm gürültüsünü azaltır.
Güç analizi	Görmek istediğin farkı baştan yaz, kaç örnek gerektiğini önceden hesapla.

Kaynak: Miller, Adding Error Bars to Evals (2024)

MODÜL 5 · ÇALIŞILMIŞ ÖRNEK: EŞLEŞTİRİLMİŞ FARK

B, A’dan 15 puan iyi. Bu yeterli mi?

Ne demek? Aynı 40 soruyu iki versiyona sorduk. Aradaki fark gerçek mi, şans mı?

Aynı 40 örnek, iki prompt

	B geçti	B kaldı
A geçti	26	3
A kaldı	**9**	2

A: 29/40 = %72,5 · B: 35/40 = %87,5

```
Örnek başına fark d: +1 (9), -1 (3), 0 (28)
Ortalama d = 6 / 40 = +0,15
SE(d) = 0,084
Aralık = [-1,5; +31,5] puan
```

Aralık sıfırı içeriyor: 40 örnekle 15 puanlık fark bile kanıtlanmış değil. Bilgiyi yalnızca uyuşmayan 12 örnek taşıyor, 9’a karşı 3.

Örnek veri · yöntem: Miller 2024

MODÜL 5 · GÜÇ ANALİZİ

10 puanlık farkı görmek için kaç örnek?

Ne demek? Ölçmeye başlamadan önce: görmek istediğin farkı görmek için kaç örnek lazım?

≈ 250

örnek, her prompt için

Senaryo: A %75, B'nin %85 olmasını bekliyorsun. %5 anlamlılık, %80 güç, eşleştirmesiz.

$$n = (1{,}96 + 0{,}84)^2 \times (0{,}75 \cdot 0{,}25 + 0{,}85 \cdot 0{,}15) / 0{,}10^2$$

$$= 7{,}84 \times 0{,}315 / 0{,}01 \approx 247$$

PM İÇİN ANLAMI

40 örnekle yalnızca çok büyük farkları görebilirsin. Küçük bir iyileştirmeyi ölçmek istiyorsan ya örnek sayısını artır, ya eşleştir, ya da hedefini daha büyük bir farka göre koy. Bu kararı etiketlemeye başlamadan önce ver.

Formül: iki oran için standart örneklem büyüklüğü · güç analizinin eval'de yeri: Miller 2024

MODÜL 5 · ALIŞTIRMA

Judge’ın sayısına hata payı koy

1. Uyum tablondaki TPR ve TNR için Wilson aralığını hesapla.
2. Judge’a güvenmek için TNR’nin alt sınırı ne olmalı? Eşiği şimdi yaz.
3. Alt sınır eşiğin altındaysa kaç “kaldı” örneği daha gerektiğini tahmin et.

> **BİTTİ SAYILIR**
>
> Eşik, sonuçları görmeden önce yazıldı.

MODÜL 6 · VERİ SETİ

Veri seti gerçek kullanımı yansıtmalı

Gerçek girdiler

En değerli kaynak. Kullanıcının gerçekten yazdığı, senin aklına gelmeyecek olan.

Zor vakalar

Hata analizinde bulduğun her kategoriden örnek. Regresyon seti buradan büyür.

Sentetik veri

Boyutlarla üret: persona × görev × zorluk. Boşluk doldurur, gerçek dağılımı temsil etmez.

Kontaminasyon: herkese açık benchmark’lar modelin eğitim verisine sızmış olabilir. Kendi verin bu yüzden değerli.

Sete göre ayar: prompt’u hep aynı sete bakarak düzeltirsen o sete uyum sağlarsın. Bir test setini ayrı tut.

MODÜL 6 · ÇALIŞILMIŞ ÖRNEK: SENTETİK BOYUTLAR

Destek botu için dört eksen

Eksen	Değerler
Konu	İade · kargo · değişim · ödeme
Ton	Sakin · aceleci · öfkeli
Dil	Türkçe · İngilizce · yazım hatalı
Tuzak	Politikada olmayan durum · çok adımlı soru · dolaylı temsilci isteği

$$4 \times 3 \times 3 \times 3 = 108$$

olası kombinasyon. Hepsi değil, gerçek veride az görülenler seçilir.

Akış: kombinasyonu seç → konuşmayı yaz ya da ürettir → oku, gerçekçi değilse at → zor vaka olarak etiketle.

Eksenler ve değerler örnek, gerçek konuşmalardan türetilir

MODÜL 6 · GOLDEN SET SATIRI

Beklenen cevap yerine geçme koşulu

Ne demek? Test setindeki her satır bir soru ve “doğru cevap neleri içermeli” listesi.

```
{
  "id": "ds-014",
  "split": "test",
  "input": "golden/ds-014.json",
  "expect": {
    "handoff": false,
    "must_mention": ["14 gün"],
    "allowed_links": ["/iade"]
  },
  "origin": "gerçek",
  "tags": ["iade", "öfkeli", "tr"]
}
```

split: geliştirme ya da test. Test satırları dondurulur.

expect: tam metin değil, kontrol edilebilir koşullar.

origin: gerçek mi sentetik mi, skoru ayrı okumak için.

tags: skoru eksenlere göre kırmak için.

Alan adları örnek · JSONL: her satır bir JSON nesnesi

MODÜL 6 · ALIŞTIRMA

Setindeki boşluğu bul

1. 40 gerçek girdini dört eksene göre etiketle.
2. Hiç görülmeyen ya da tek örnekli kombinasyonları listele.
3. Bunlardan 5 sentetik vaka üret, oku, gerçekçi olanları say.
4. Tutulanları golden.jsonl’a origin: sentetik ile ekle.

BİTTİ SAYILIR

Skoru gerçek ve sentetik vakalarda ayrı ayrı okuyabiliyorsun.

Eval’i her değişiklikte koş

```
from inspect_ai import Task, task
from inspect_ai.dataset import json_dataset
from inspect_ai.scorer import model_graded_qa
from inspect_ai.solver import generate

@task
def destek_politikasi():
    return Task(
        dataset=json_dataset("golden.jsonl"),
        solver=generate(),
        scorer=model_graded_qa(),
    )
```

Dataset: girdi ve beklenen davranış (input, target).

Solver: modele ne yapılacağı: prompt, araç, zincir.

Scorer: çıktının nasıl notlanacağı: kod ya da judge.

promptfoo aynı fikri YAML ile kurar: prompts, providers, tests, assert.

Maliyet: her judge kararı bir model çağrısı. Toplam = örnek × tekrar × kriter.

Kaynak: Inspect AI dokümantasyonu (UK AI Security Institute ve Meridian Labs)

MODÜL 7 · PROMPTFOO

Aynı eval, YAML ile

```yaml
prompts:
  - file://prompts/destek.txt
providers:
  - anthropic:messages:claude-sonnet-5-5
tests:
  - vars:
      soru: İade süresi ne kadar?
    assert:
      - type: contains
        value: 14 gün
      - type: llm-rubric
        value: Cevap politikayla çelişmiyor.
```

prompts: sınanan sistem.

providers: model. İki model yazılırsa yan yana karşılaştırır.

contains: kod assertion.

llm-rubric: judge. Tek cümlelik rubrik yerine Modül 4’teki tam prompt kullanılır.

Kaynak: promptfoo dokümantasyonu · dosya yolları ve model adı örnek

MODÜL 7 · RİTİM

Hangi eval ne zaman koşar

Ne demek? Ucuz kontroller her değişiklikte, pahalı olanlar daha seyrek çalışır.

Ne zaman	Ne koşar	Maliyet
Her commit	Kod assertion’ları, tüm set	Ücretsiz, saniyeler
Prompt değişikliği	Judge’lar, geliştirme seti	Örnek × tekrar × kriter çağrı
Sürüm öncesi	Tam set, test seti, önceki sürümle eşleştirilmiş karşılaştırma	En pahalı otomatik koşum
Düzenli aralıkla	Yeni gerçek çıktılarda hata analizi	Senin zamanın

REGRESYON KURALI

Düzelttiğin her hata sete bir vaka olarak girer. Set böylece ürünün geçmişte yaptığı hataların hafızası olur.

Ritim Husain’in üç seviyesinin maliyet sırasını izliyor (Your AI Product Needs Evals, 2024)

MODÜL 7 · ALIŞTIRMA

Eval’i bir komutla koşturulabilir yap

1. Kod assertion’larını projenin test süitine (örneğin pytest) ekle.
2. Judge’ı Inspect ya da promptfoo ile kur, önce 3 vakayla koş.
3. Komutun verdiği skoru, aynı 3 vaka için elle hesapladığınla karşılaştır.

> **BİTTİ SAYILIR**
>
> Tek komut, elle hesapla aynı sonucu veriyor.

MODÜL 8 · BİTİRME ÖDEVİ

Kendi ürününde uçtan uca bir eval

1 · Seç ve topla

Kendi ürününden bir akış seç. Ürünü olmayan destek botunu kullanır. 40 gerçek konuşma topla.

2 · Oku

40 çıktıyı açık ve eksen kodla, en sık üç hatayı çıkar.

3 · Judge yaz

Her hata için ikili bir judge: geçti/kaldı tanımı ve örnekler.

4 · Etiketle

40 çıktıyı kendin etiketle: 20 geliştirme, 20 test.

5 · Hizala

Judge'ı geliştirme setinde düzelt, test setinde TPR ve TNR'yi bir kez ölç.

6 · Karşılaştır

Prompt'u değiştir, aynı 40 örnekte eşleştirilmiş farkı hata payıyla raporla.

BAŞARI ÖLÇÜTÜ

Judge test setinde TPR ve TNR ≥ [eşik, örn. %80: sen belirle]. Önce/sonra farkı hata payıyla raporlandı. Hakem judge'ın sözü değil, senin etiketlerin.

MODÜL 8 · TESLİM PAKETİ

eval/ klasörüne beş dosya

Dosya	İçerik	Bitti ölçütü
`taksonomi.md`	Kategoriler, tanım, sınır vakası, sayı	En az 40 çıktı okundu
`golden.jsonl`	40 vaka, split ve origin etiketli	Test seti dondurulduu
`graders/*.md`	Judge gerektiren her kategori için bir prompt	Sınır vakası yazılı
`uyum.md`	Test setinde TPR, TNR, kappa	Wilson aralığıyla
`karsilastirma.md`	Önce/sonra farkı, eşleştirilmiş	Aralık ve uyuşmayan örnekler okunmuş

Kod assertion’ları ayrı dosya değil: projenin mevcut test süitine eklenir.

KONTROL LİSTESİ

Bir eval sonucuna güvenmeden önce

1 · Kriter çıktılar okunarak mı çıktı?

2 · Kodla yakalanabilen judge'a mı verildi?

3 · Judge ikili mi, tek kriterli mi?

4 · TPR ve TNR ayrı ayrı ölçüldü mü?

5 · Test seti hiç görülmeden mi ölçüldü?

6 · Hata payı raporlandı mı?

7 · n küçükse Wilson ya da Bayes mi?

8 · Karşılaştırma eşleştirilmiş mi?

9 · Set gerçek kullanımı temsil ediyor mu?

10 · Uyuşmayan örnekler okundu mu?

KAYNAKLAR

Birincil kaynaklar, okuma sırasıyla

Kaynak	Ne için	Modül
Husain (2024), Your AI Product Needs Evals	Katmanlar, ritim	1, 3, 7
Strauss & Corbin, Basics of Qualitative Research	Açık ve eksen kodlama	2
Shankar vd. (UIST 2024), Who Validates the Validators?	Kriter kayması	2, 4
Husain (2024), Creating a LLM-as-a-Judge That Drives Business Results	Critique shadowing	2, 4
Zheng vd. (2023), Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena	Judge yanlılıkları	4
Miller (2024), Adding Error Bars to Evals	Hata payı, güç	5
Bowyer vd. (ICML 2025), Don’t Use the CLT in LLM Evals…	Küçük n	5
Liang vd. (2022), Holistic Evaluation of Language Models	Çok boyutlu ölçüm	3, 6
Inspect AI ve promptfoo dokümantasyonu	Araçlar	7